

# Introducción a la librería Pytorch

Diego Andrade Canosa



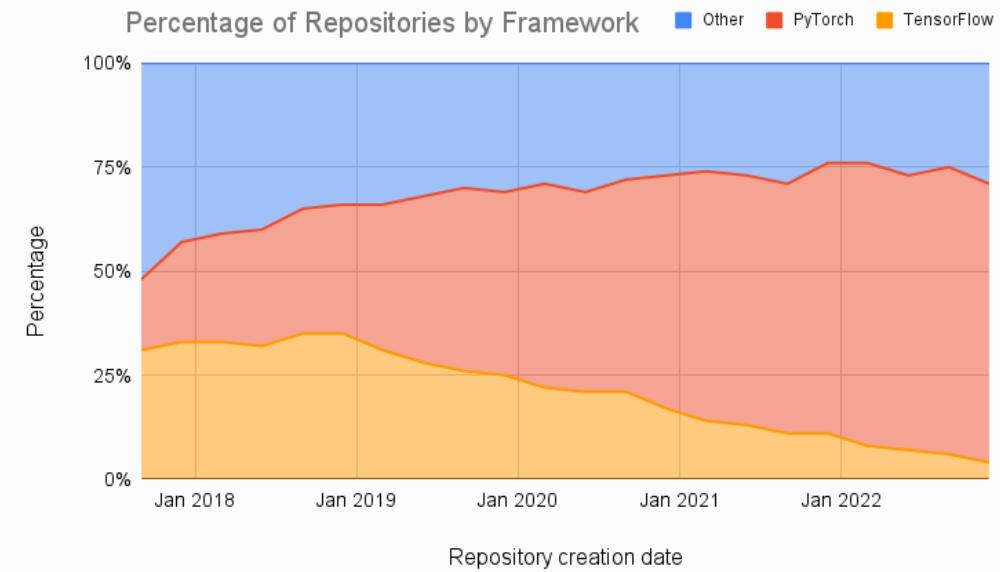
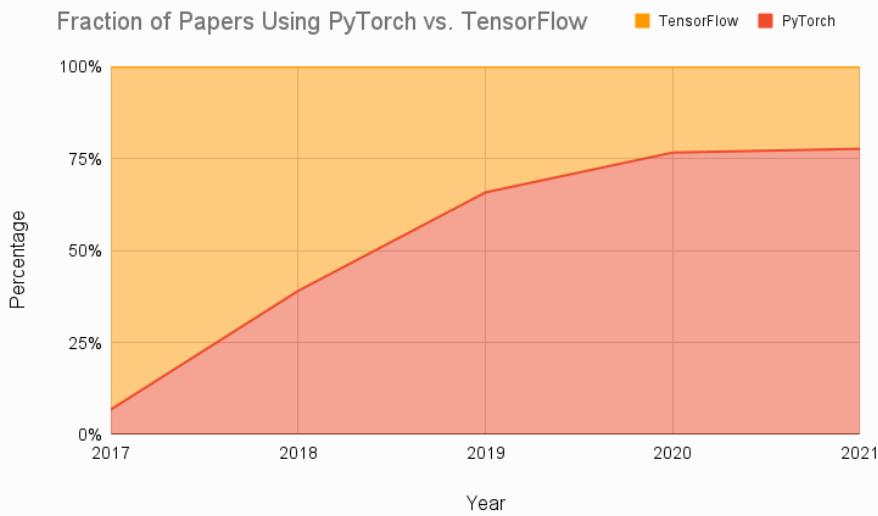
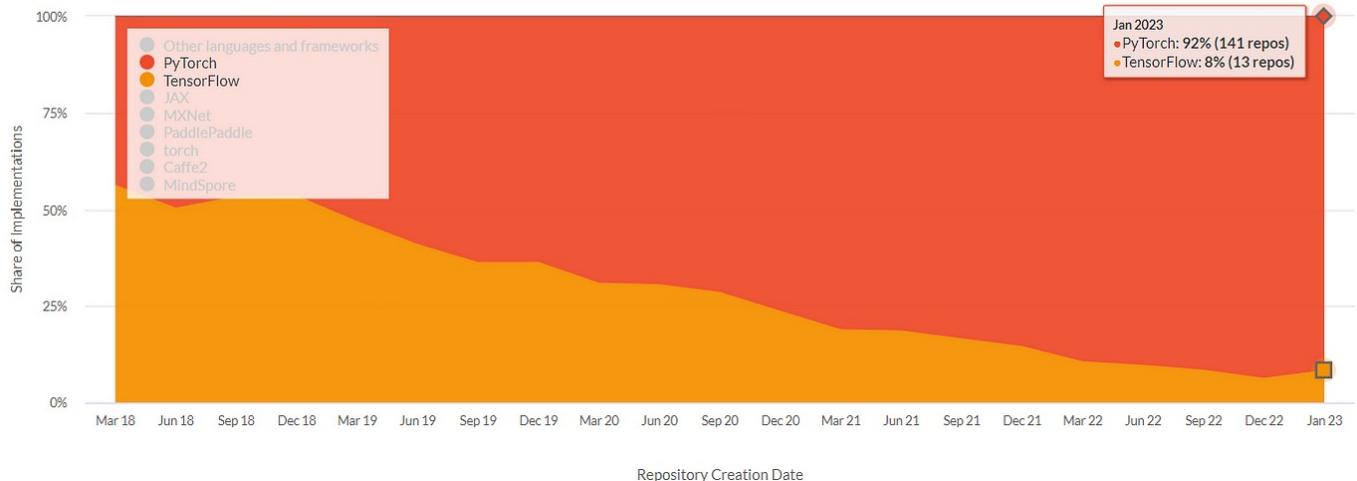
- Conceptos clave de Pytorch
  - o Tensores
    - Transformaciones
  - o Variables y gradientes
  - o Diferenciación automática
- Creación y composición de la arquitectura de red
- Los módulos nn.Module y nn.Sequential de Pytorch
  - o Tipos de capas en Pytorch
  - o Optimizadores y funciones de pérdida
  - o Bucles de entrenamiento
    - Pasada Forward
    - Backpropagation



# Introducción a la librería Pytorch



Paper Implementations grouped by framework



# Pytorch: Génesis

- Librería creada en el año 2016 por FAIR (Facebook AI Research Lab)
  - Proyecto Adam Paszke (Internship)
  - Sucesor de la librería *torch* (basada en *Lua*)
  - Influenciado por la librería *chainer*
- Cronograma
  - Año 2016: Versión inicial
  - Año 2018: Versión 1.0 ( fusión con Caffe)
  - Año 2019: Pytorch Lightning
  - Año 2023 (marzo!): Pytorch 2.0



[Fuente](#)

# Fortalezas

- Gran penetración en la comunidad investigadora
- Ventaja conceptual: Dynamic Computation Graph
- Facilidad de uso
- Flexibilidad
- Mucha base de código abierto en:
  - Visión por Computador
  - Procesado de Lenguaje Natural
  - Sistemas recomendadores
  - Procesado de señal



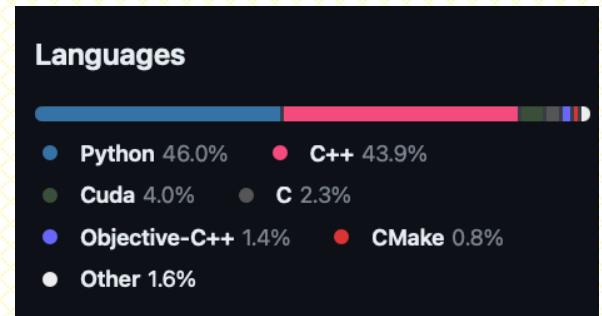
# Ecosistema Pytorch

- Conjunto de herramientas y librerías que enriquecen y complementan al núcleo principal de Pytorch
- <https://pytorch.org/ecosystem/>
  - Domain-specific
    - NeMO
    - Diffusers
    - PennyLane
    - Transformers
  - HPC
    - Lightning
    - DeepSpeed
    - FairScale <https://github.com/facebookresearch/fairscale>
    - Accelerate
    - Ray
  - Other
    - TorchMetrics

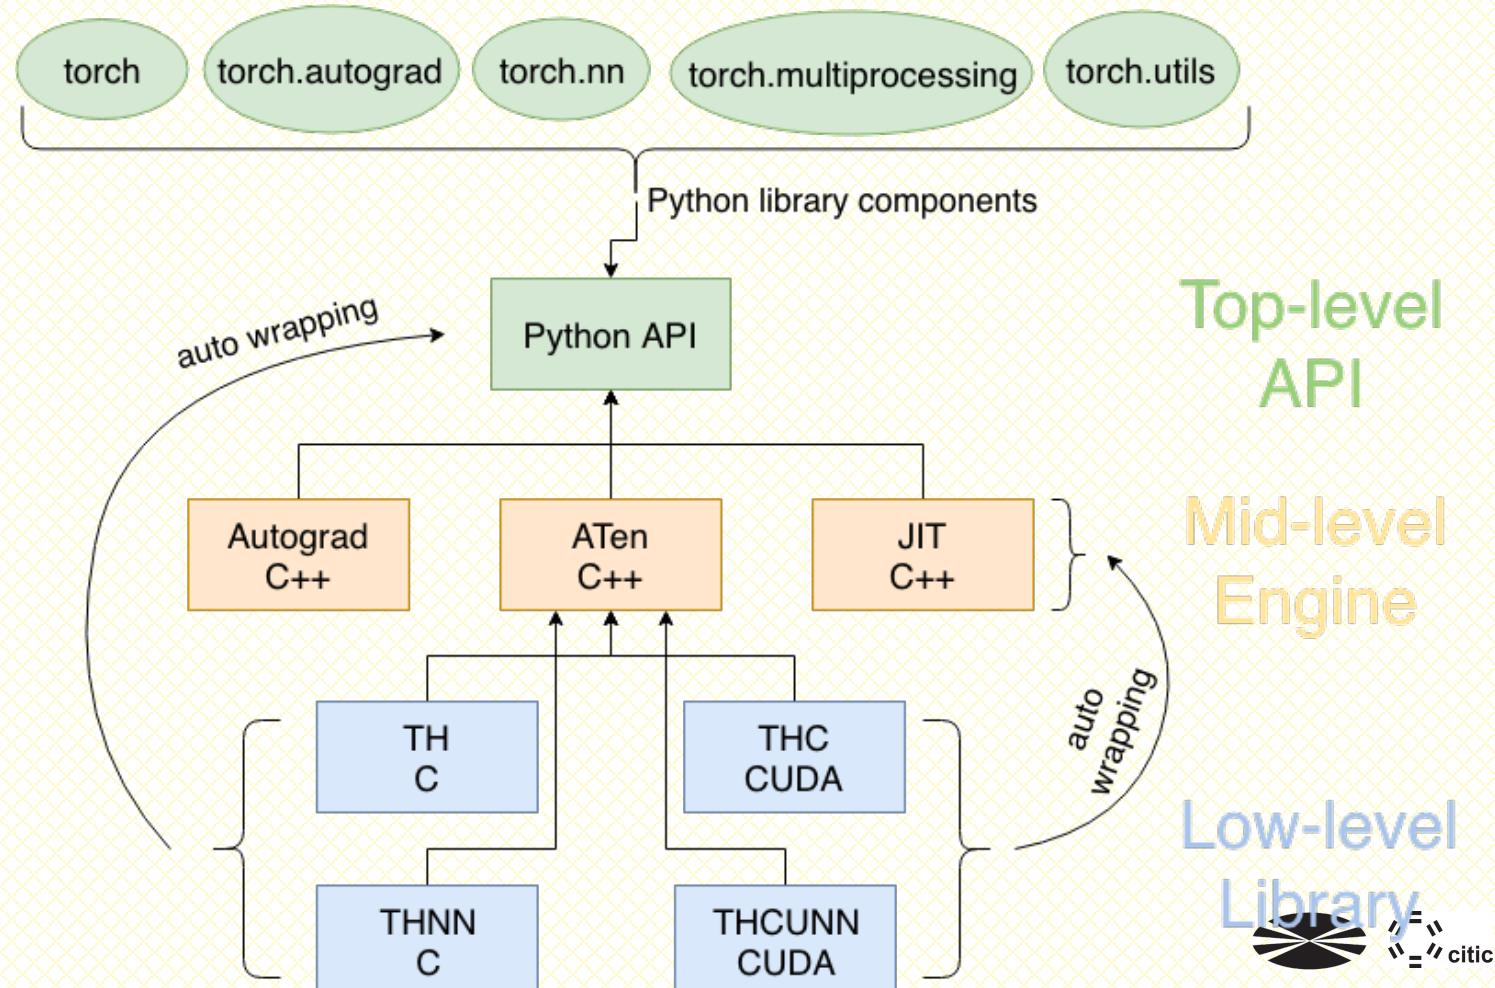


# Principios de diseño

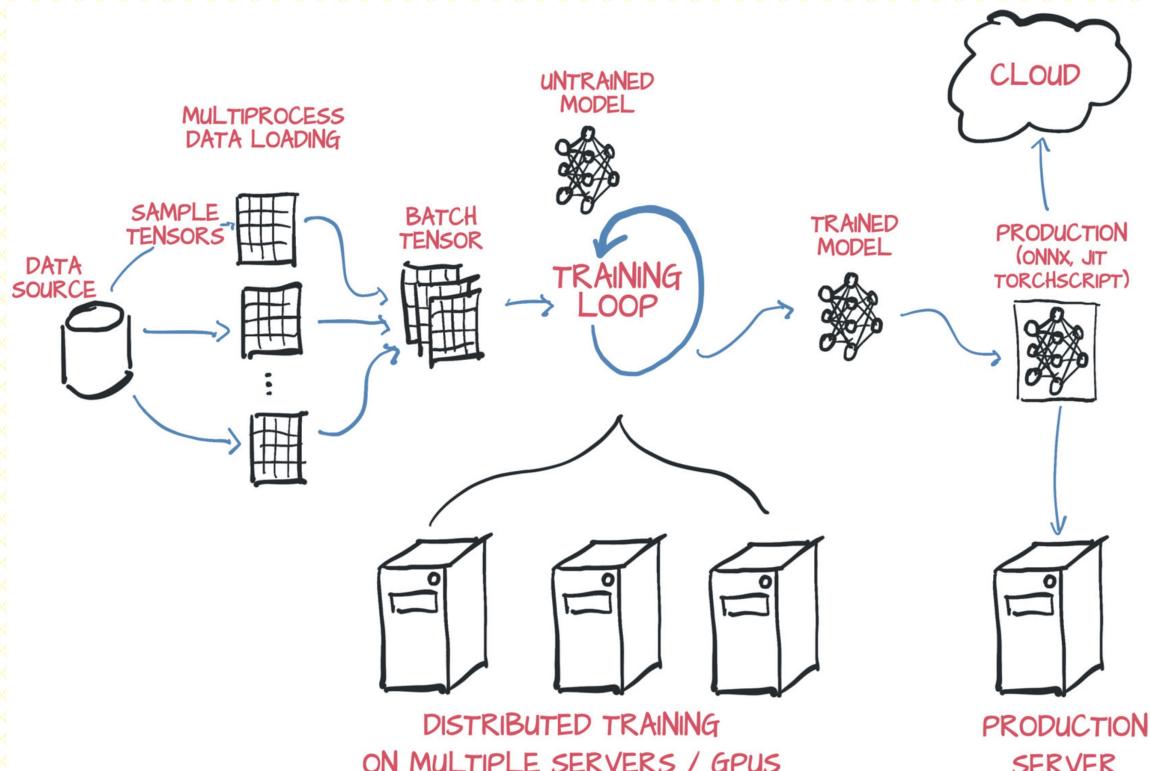
- Principio 1: Usable antes que rápido
- Principio 2: Simple antes que fácil
- Principio 3: Python primero



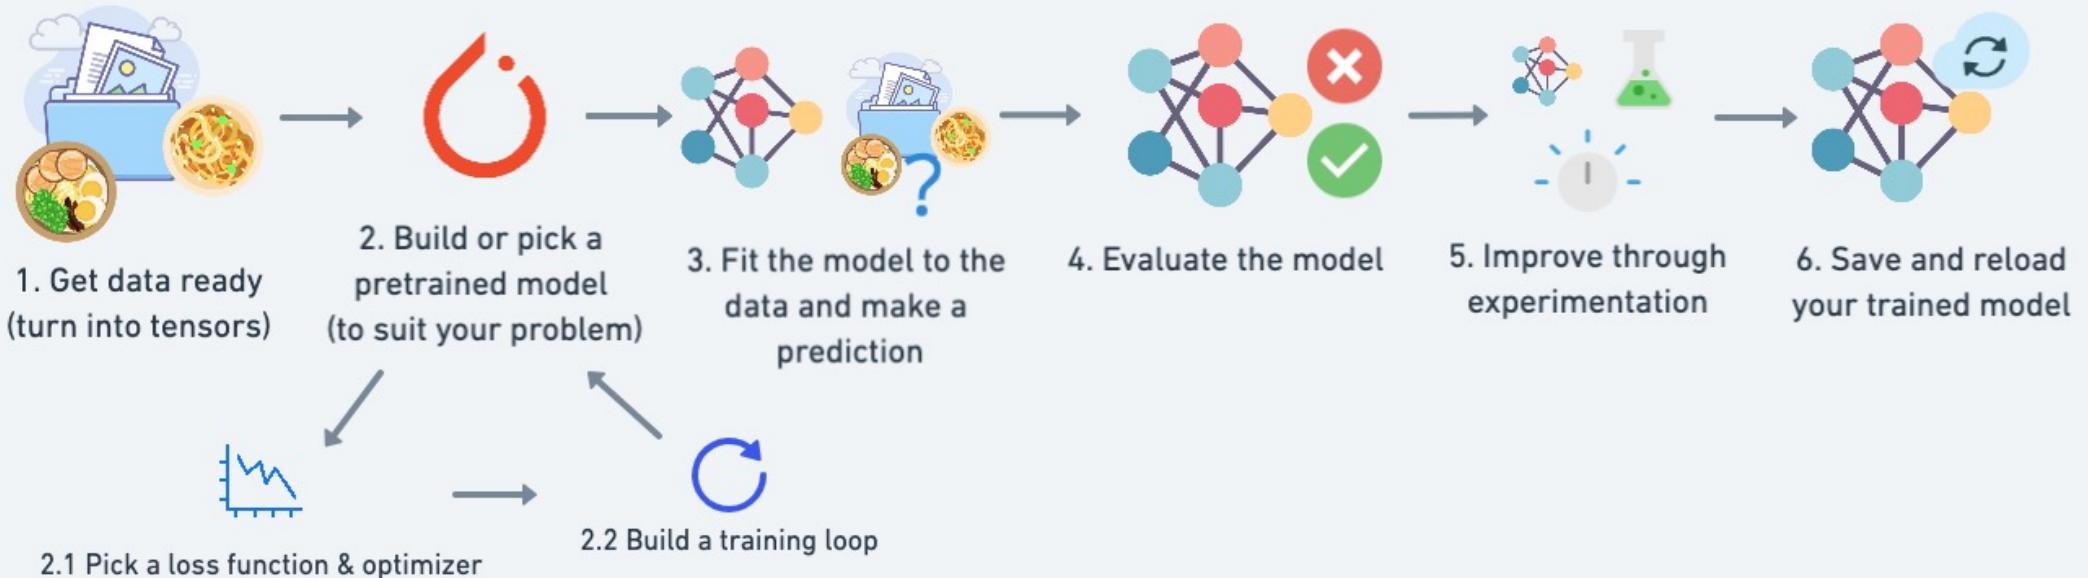
# Estructura de módulos de Pytorch



# Pytorch: Uso

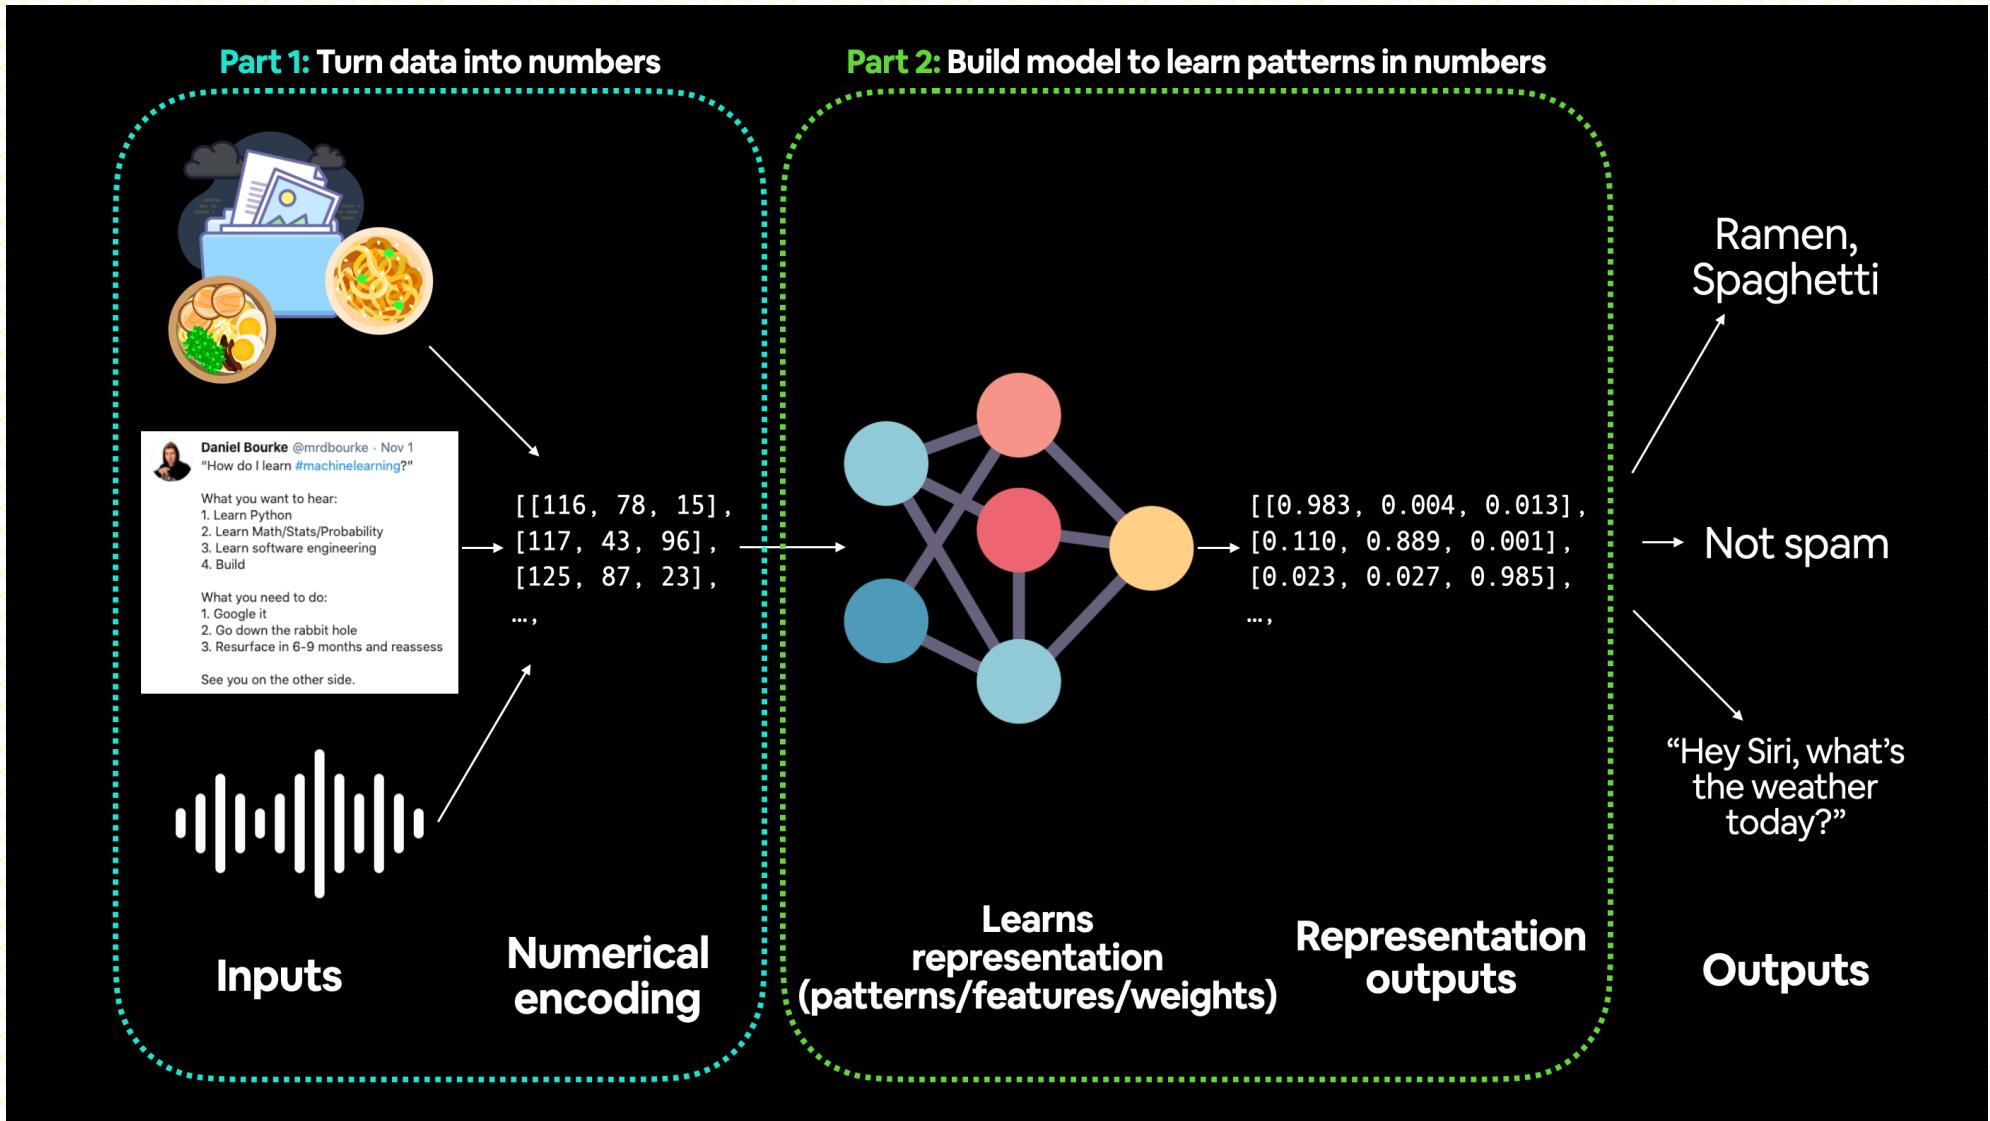


## A PyTorch Workflow



Fuente: [https://www.learnpytorch.io/01\\_pytorch\\_workflow/](https://www.learnpytorch.io/01_pytorch_workflow/)





```
1 # Create a linear regression model in PyTorch
2 class LinearRegressionModel(nn.Module):
3     def __init__(self):
4         super().__init__()
5
6         # Initialize model parameters
7         self.weights = nn.Parameter(torch.randn(1,
8             requires_grad=True,
9             dtype=torch.float
10        ))
11
12         self.bias = nn.Parameter(torch.randn(1,
13             requires_grad=True,
14             dtype=torch.float
15        ))
16
17     # forward() defines the computation in the model
18     def forward(self, x: torch.Tensor) -> torch.Tensor:
19         return self.weights * x + self.bias
```

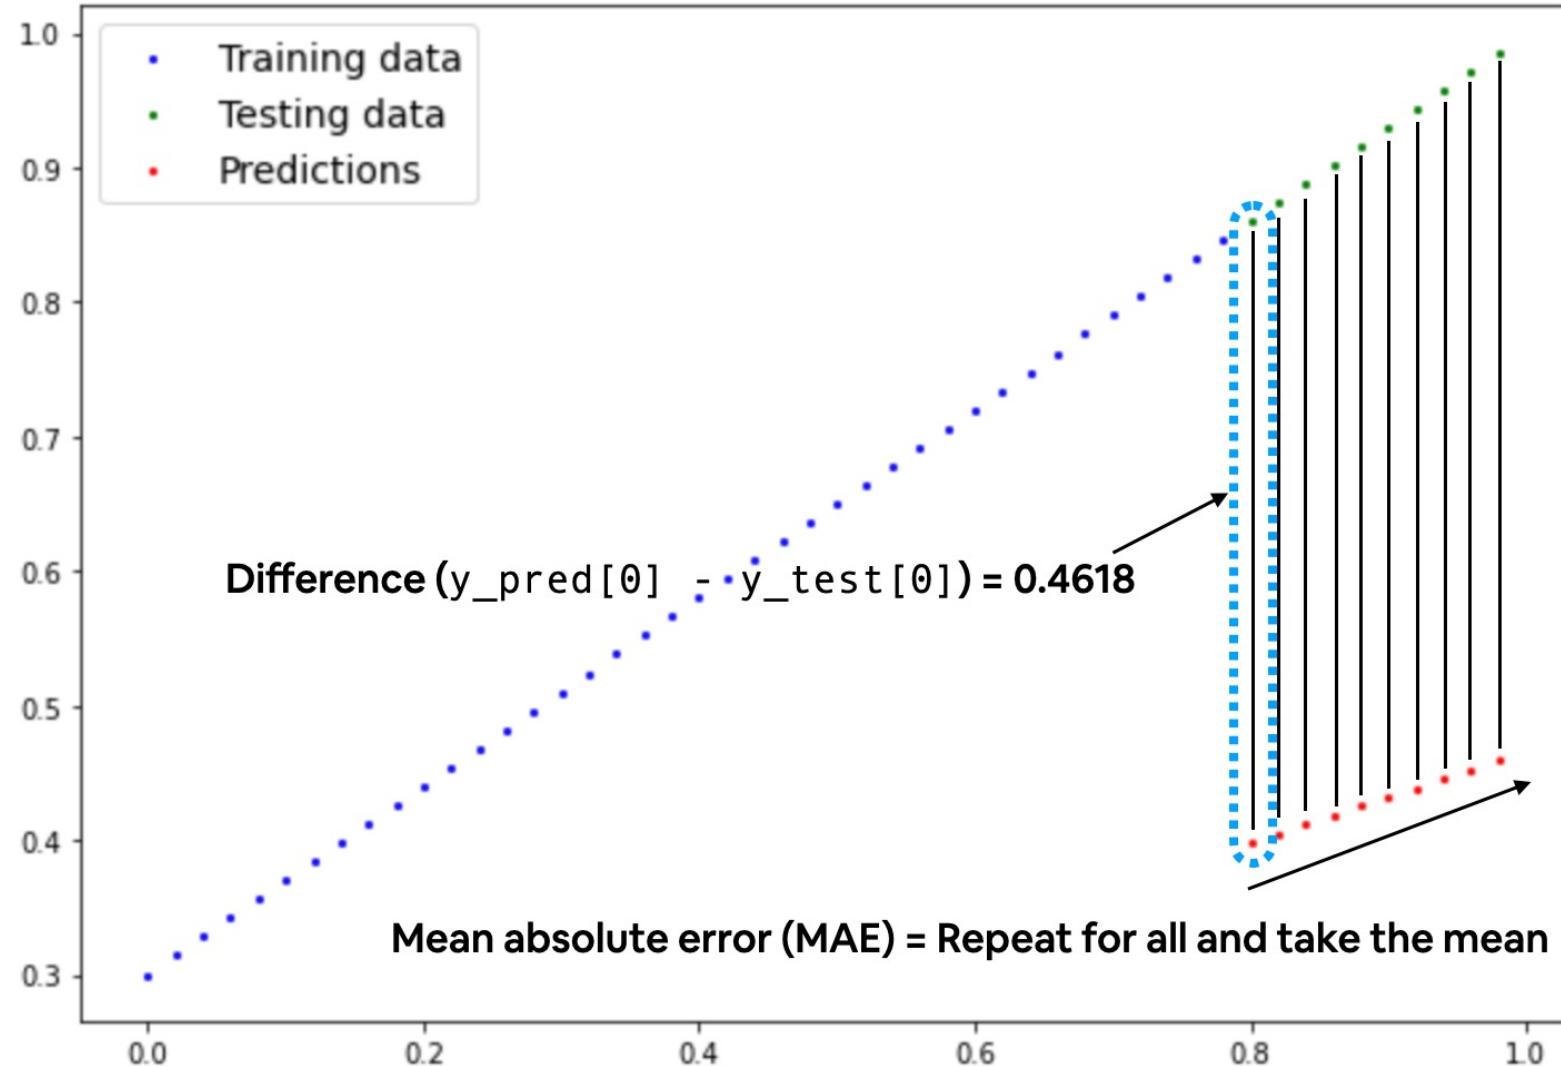
**Subclass `nn.Module`**  
(this contains all the building blocks for neural networks)

Initialise **model parameters** to be used in various computations (these could be different layers from `torch.nn`, single parameters, hard-coded values or functions)

`requires_grad=True` means PyTorch will track the gradients of this specific parameter for use with `torch.autograd` and gradient descent (for many `torch.nn` modules, `requires_grad=True` is set by default)

Any subclass of `nn.Module` needs to override `forward()` (this defines the forward computation of the model)





# PyTorch training loop

```
# Pass the data through the model for a number of epochs (e.g. 100)
for epoch in range(epochs):
    # Put model in training mode (this is the default state of a model)
    model.train()
    # 1. Forward pass on train data using the forward() method inside
    y_pred = model(X_train)
    # 2. Calculate the loss (how different are the model's predictions to the true values)
    loss = loss_fn(y_pred, y_true)
    # 3. Zero the gradients of the optimizer (they accumulate by default)
    optimizer.zero_grad()
    # 4. Perform backpropagation on the loss
    loss.backward()
    # 5. Progress/step the optimizer (gradient descent)
    optimizer.step()
```

Note: all of this can be turned into a function

Pass the data through the model for a number of **epochs** (e.g. 100 for 100 passes of the data)

Pass the data through the model, this will perform the **forward()** method located within the **model** object

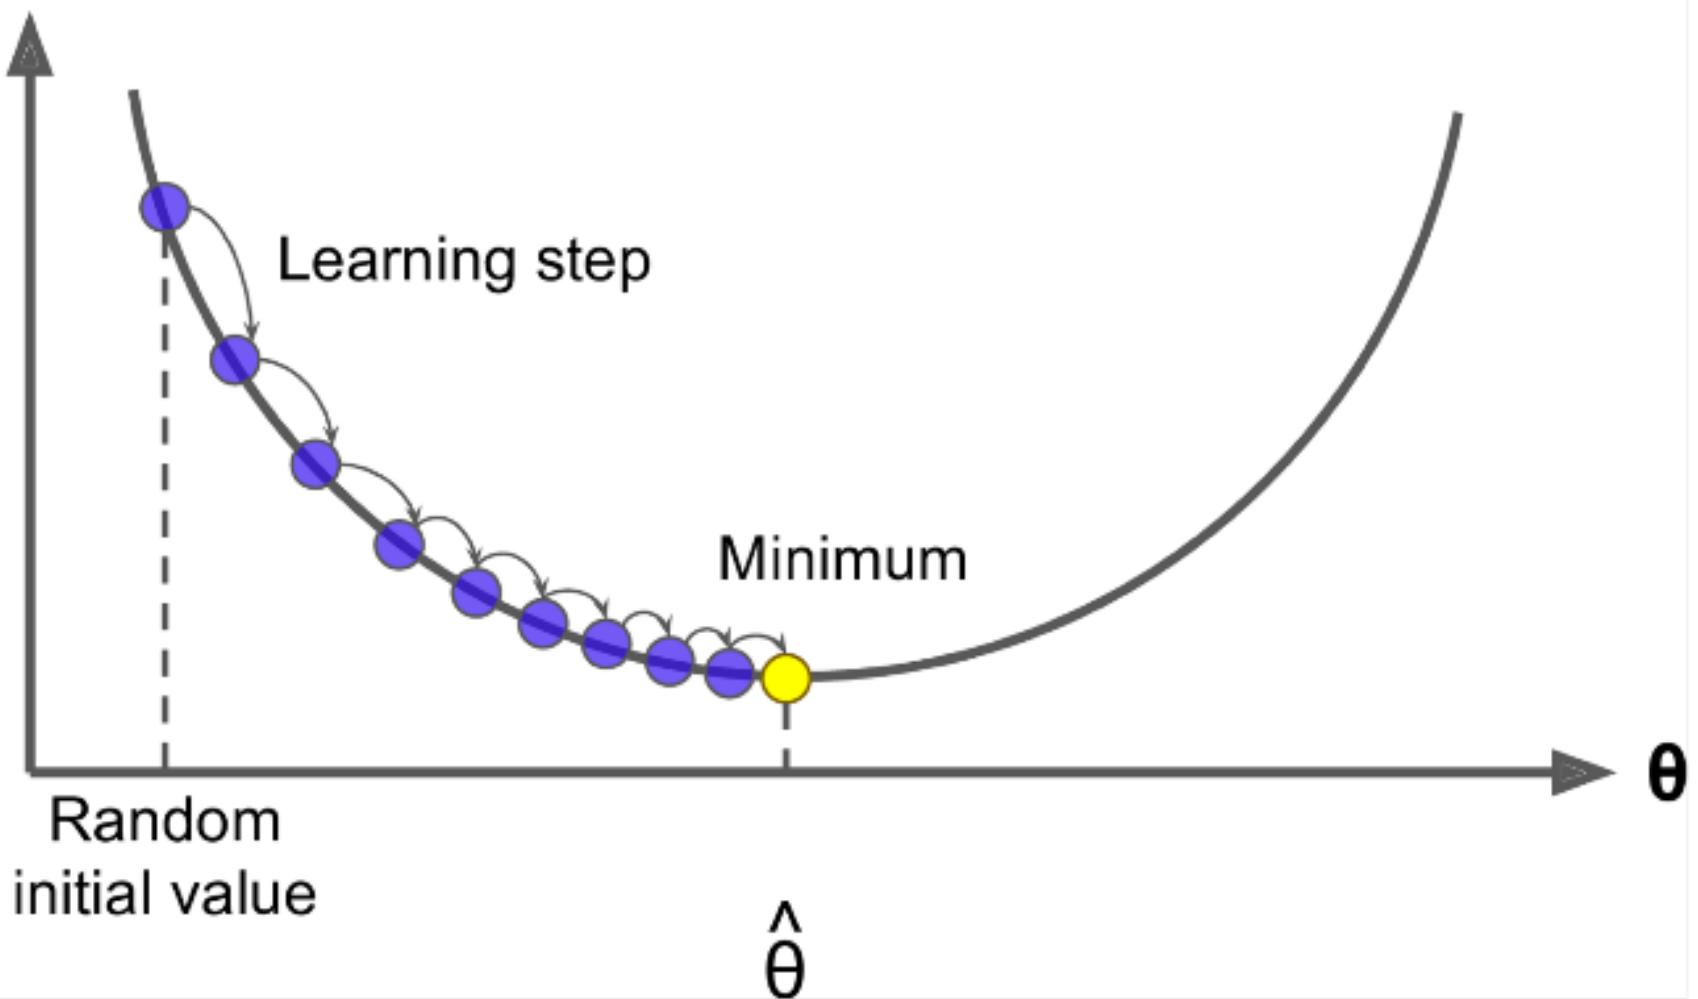
Calculate the **loss value** (how wrong the model's predictions are)

Zero the **optimizer gradients** (they accumulate every epoch, zero them to start fresh each forward pass)

Perform **backpropagation** on the loss function (compute the gradient of every parameter with `requires_grad=True`)

Step the **optimizer** to update the model's parameters with respect to the gradients calculated by `loss.backward()`

**Cost**



# PyTorch testing loop

```
1 # Setup empty lists to keep track of model progress
2 epoch_count = []
3 train_loss_values = []
4 test_loss_values = []
5
6 # Pass the data through the model for a number of epochs (e.g. 100) pochs):
7 for epoch in range(epochs):
8
9     ### Training loop code here #####
10
11    ### Testing starts #####
12
13    # Put the model in evaluation mode
14    model.eval()
15
16    # Turn on inference mode context manager
17    with torch.inference_mode():
18        # 1. Forward pass on test data
19        test_pred = model(X_test)
20
21        # 2. Caculate loss on test data
22        test_loss = loss_fn(test_pred, y_test)
23
24    # Print out what's happening every 10 epochs
25    if epoch % 10 == 0:
26        epoch_count.append(epoch)
27        train_loss_values.append(loss)
28        test_loss_values.append(test_loss)
29        print(f"Epoch: {epoch} | MAE Train Loss: {loss} | MAE Test Loss: {test_loss} ")
```

Note: all of this can be turned into a function

Create empty lists for storing useful values (helpful for tracking model progress)

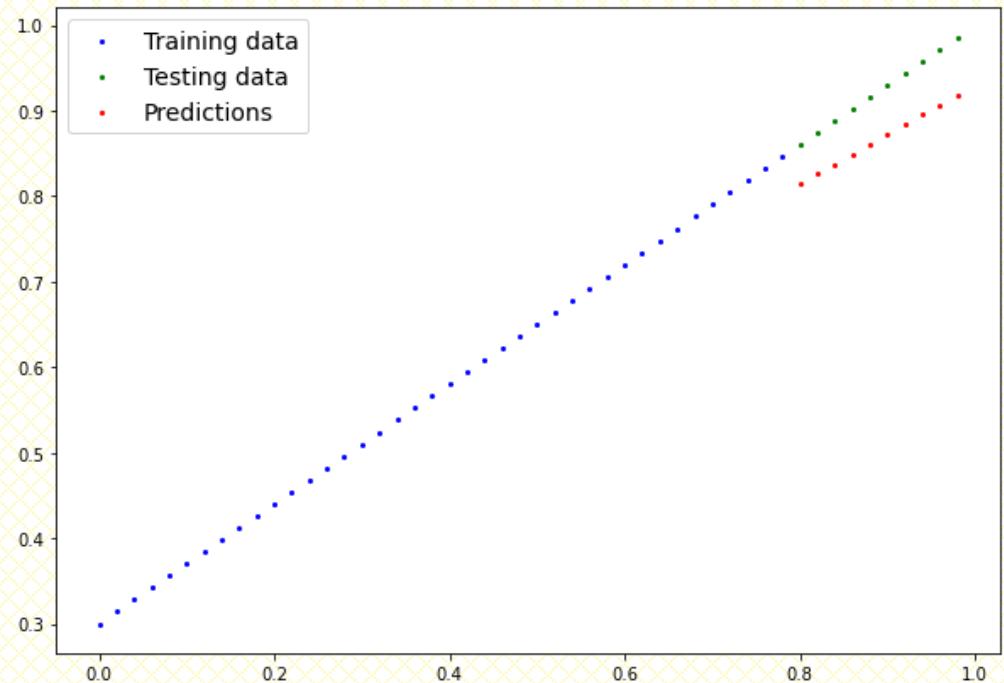
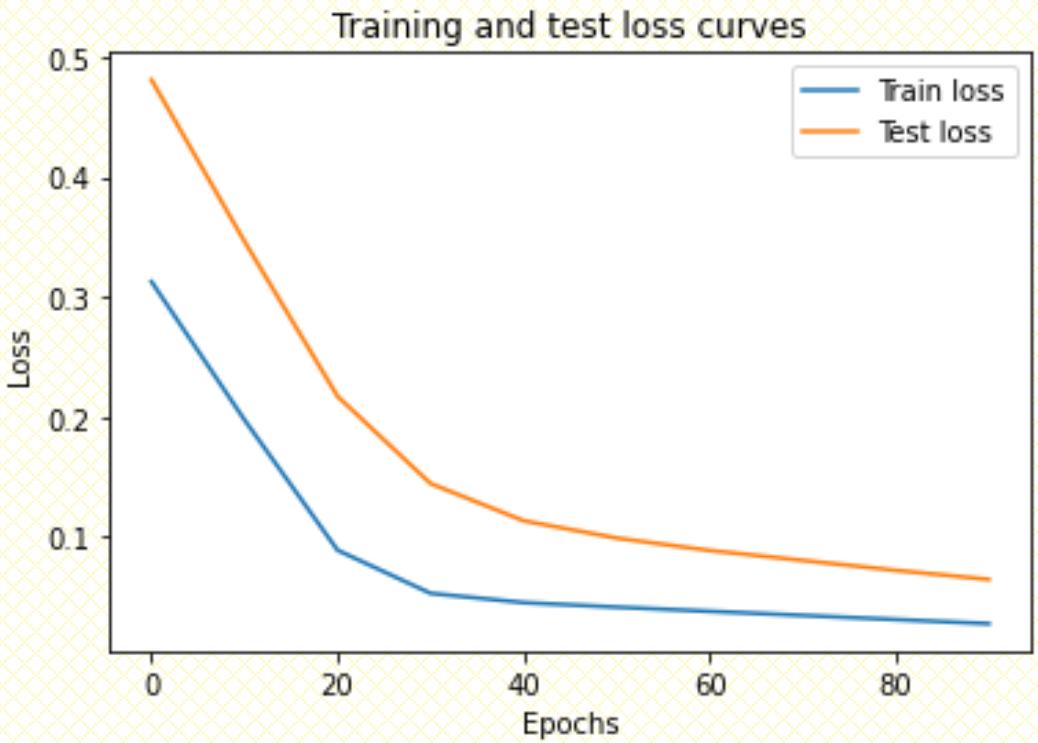
Tell the model we want to evaluate rather than train (this turns off functionality used for training but not evaluation)

Turn on `torch.inference_mode()` context manager to disable functionality such as gradient tracking for inference (gradient tracking not needed for inference)

Pass the test data through the model (this will call the model's implemented `forward()` method)

Calculate the test loss value (how wrong the model's predictions are on the test dataset, lower is better)

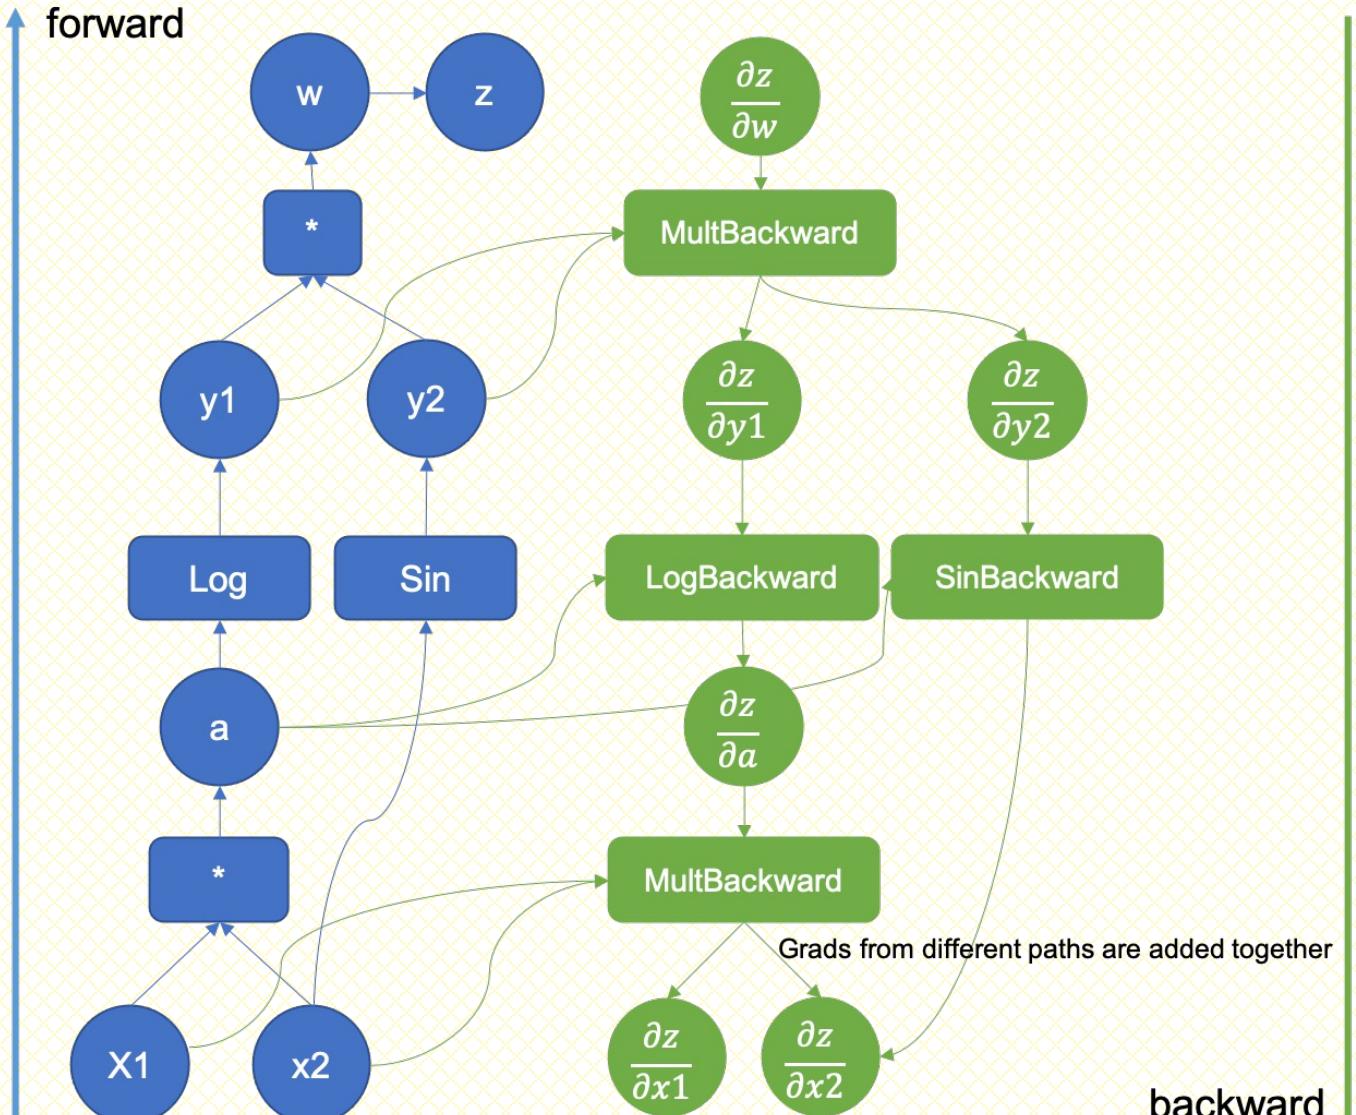
Display information outputs for how the model is doing during training/testing every ~10 epochs (note: what gets printed out here can be adjusted for specific problems)



# Dynamic Computation Graph (DCG)

- Aproximación dinámica “define by run”, (vs “define and run”, estática)
- Más intuitivo y flexible que la aproximación estática (static computation graph)
- Menos posibilidades de optimización del cómputo
- Es una diferencia básica respecto a TF (<2.0)





# Abstracciones

- Tensores: estructura de datos multidimensional donde se almacenan los diversos elementos del modelo: parámetros (pesos), bias, entradas, salidas
- Contenedores (*container*): estructuras a las que se asocian los distintos componentes de un modelo, así como su operación
- Optimizadores: artefacto que permite calcular los gradientes de los pesos en función de la salida de la función de pérdida
- Autograd: mecanismo que crea el DCG y permite calcular las derivadas parciales



# Bloques constructores

- API Python
  - torch
  - torch.nn
- Librerías secundarias
  - Torchtext (Texto)
  - Torchaudio (Audio)
  - Torchvision (Visión por computador)
  - Torcharrow (Data frame, tabular data)
  - TorchData (Pipelines de procesado de datos)
  - TorchRec (Sistemas recomendadores)
  - TorchServe (Servidores)
  - Torchx (Lanzador para aplicaciones Pytorch)



# torch

- Tensores
  - Definición, Creación, Indexación, Transformación, Random sampling, Serialización, Operadores matemáticos (aritméticos, lógicos, espectrales, Blas/lapack, operaciones foreach, otros)
- Utilidades
- Optimizaciones
- Configuración del engine

<https://pytorch.org/docs/stable/torch.html>



# **torch.nn**

- Definición de capas
  - Convolucionales, Pooling, Padding, Normalization, Recurrent, Dropout...
- Contenedores (containers)
  - Module, Sequential
- Funciones
  - Distance, Loss, Quantized

<https://pytorch.org/docs/stable/nn.html>



# TorchVision

- Paquete orientado a la resolución de problemas de visión por computador
- Proporciona:
  - Técnicas para transformar y aumentar imágenes (Geometría, color, composición, conversión, auto-augmentation)
  - Datapoints (Imágenes, Vídeo)
  - Modelos (Resnet, Mobilenet, Yolo, Inception, VGG, etc...)
  - Datasets (CIFAR, MNIST, ...)
  - Utilidades
  - Entrada/Salida (para imágenes y videos)
  - Extracción de características



# TorchAudio



- Paquete que agrupa varias utilidades relacionadas con el procesamiento de audio y de señal en general
- Proporciona:
  - Modelos (Conformer, HuBERT, DeepSpeech, etc...)
  - Datasets (CMU, GTZAN, LibriSpeech, etc...)
  - Pipelines: permiten usar modelos preentrenados para realizar tareas específicas
  - Componentes para la Entrada/Salida (StreamReader, StreamWriter, play\_audio)



# TorchText



- Paquete que agrupa varias utilidades realizadas con el procesamiento de lenguaje
  - Es un desarrollo incipiente basado en la filosofía de otros paquetes más longevos como torchaudio y torchvision
- Proporciona:
  - Modelos (Roberta)
  - Utilidades (extraer archivo, descargar de url,...)
  - Transformaciones
  - Vocab (mapeado de palabras a índices)
  - Datasets
  - Elementos funcionales
  - Contenedores específicos (MultiheadAttentionContainer)



# TorchArrow

- Conjunto de utilidades para el procesado de datos tabulares (Data Frame)
- Proporciona:
  - DataFrame (Creación, Inspección, Transformación, Estadísticas, Aritmética)
  - Column: Estructura de datos unidimensional con datos de un único tipo de datos (numérico, string, list)



# TorchData

- Paquete con componentes que permiten la construcción de pipelines para la carga de datos
- Proporciona:
  - Pipelines iterables (accesibles elemento a elemento)
  - Pipeline Map-style (accesibles clave-valor)
  - Utilidades
  - DataLoader2: Versión alternativa de `torch.utils.data.DataLoader`



# TorchRec

- Paquete que contiene varias utilidades para construir sistemas recomendadores



# TorchServe

- Paquete que contiene utilidades para la creación de servidores de modelos
- Proporciona:
  - API de gestión de modelos
  - API de inferencia
  - Soporte para distintas soluciones tecnológicas (Sagemaker, Mlflow, Kubeflow, etc...)



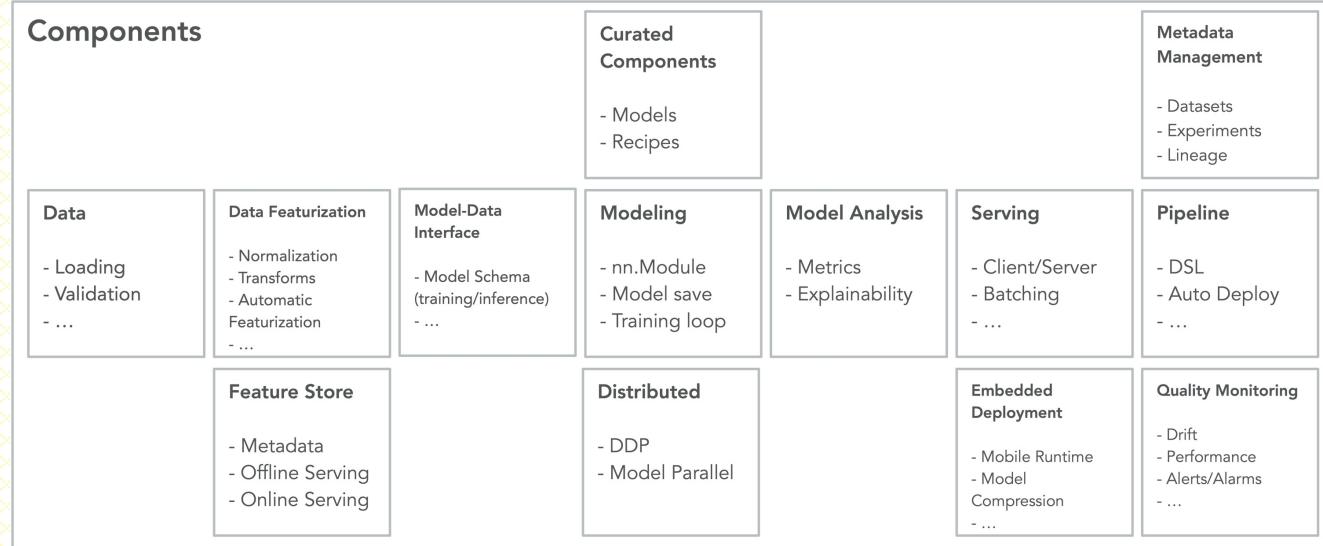
# torchx

Lanzador para Pytorch  
Tipo srun o qsub

Funciona con Slurm, Ray, AWS, Docker,  
Kubernetes, etc...

Permite ejecución local, remota y  
distribuida

<https://pytorch.org/torchx/latest/quicksstart.html>



# Referencias y materiales adicionales



# Introducción al Deep Learning

- <https://developer.nvidia.com/blog/deep-learning-nutshell-core-concepts/>
- <https://mlu-explain.github.io>
- <https://aws.amazon.com/es/machine-learning/mlu/>



# Referencias

- Pytorch Internals: <http://blog.ezyang.com/2019/05/pytorch-internals/>
- Pytorch Design Philosophy:  
<https://pytorch.org/docs/stable/community/design.html>
- Pytorch: <https://se.ewi.tudelft.nl/desosa2019/chapters/pytorch/>
- A Tour of Pytorch Internals (Part I): <https://pytorch.org/blog/a-tour-of-pytorch-internals-1/>
- Pytorch CheatSheet:  
<https://pytorch.org/tutorials/beginner/ptcheat.html>
- Pytorch Deep Learning Framework: Speed+Usability:  
<https://syncedreview.com/2019/12/16/pytorch-deep-learning-framework-speed-usability/>

